

L'échec comme théorème :
objets d'erreur certifiés, audit de fidélité et dernier
kilomètre instrumenté
dans un noyau LCF pour la *Théorie des ensembles* de
Bourbaki

Karl [nom complet]*

Préprint — août 2026

Traduction française de travail — la version de référence est l'anglaise (`main.tex`).

Résumé

Les assistants de preuve certifient le succès : un théorème passe la vérification ou non. Nous présentons un système dans lequel l'*échec* est certifié avec la même rigueur. Travaillant dans un noyau LCF implémenté directement sur le système formel propre à Bourbaki — l'opérateur τ et ses assemblages abrégés, un formalisme qu'aucune mécanisation antérieure n'habite —, nous développons (i) des *objets d'échec certifiés* : toute impasse porte un certificat vérifié par le noyau (par exemple une dérivation de l'absurdité à partir d'une hypothèse résiduelle) et un périmètre *calculé* ; (ii) une trichotomie opérationnelle classant toute hypothèse ouverte comme déchargeable, réfutable ou indépendante — les deux premiers verdicts sont des objets du noyau, le troisième un défaut dont nous énonçons explicitement le statut épistémique ; (iii) la *mesure de dette* : un théorème annoncé sans hypothèse est mesuré consommant 53 axiomes de théories ad hoc invisibles à son énoncé, ce qui motive une comptabilité correcte de ce qu'une dérivation suppose réellement ; et (iv) un *audit de fidélité mécanisé* contre le texte source à la granularité de la page, sous lequel deux défauts de transcription d'axiome ont été détectés en *dérivant une contradiction*, réparés en restaurant la forme du livre, et prouvés corrigés par l'impossibilité de la re-dériver. Un balayage de similarité de Weisfeiler-Leman réduit la détection d'une de ces incohérences d'une investigation à deux agents de 95 minutes à une requête de quelques secondes. Nous rapportons une semaine d'exploitation instrumentée — trois défauts d'axiome trouvés et réparés, un théorème vacueux révoqué puis réhabilité par décharge, une suite de 3909 tests — et soutenons que le corpus d'échecs certifiés qui en résulte, indisponible dans tout corpus de preuves existant, est le substrat

*ISEP Paris. Contact : [courriel]. Code et corpus certifié : [URL du dépôt et empreinte du commit étiqueté au moment de la soumission].

d'entraînement manquant pour les systèmes d'IA destinés à *créer* des théories plutôt qu'à simplement chercher des preuves.

1 Introduction

Les assistants de preuve sont des machines à certitude : un théorème passe la vérification ou non, et les bibliothèques accumulent les succès. Tout le reste — les tentatives ratées, les routes qui ont fini en impasse, l'hypothèse qui s'est révélée réfutable, l'axiome mal transcrit depuis le livre — est jeté et ne survit, au mieux, que sous forme de messages de commit et de folklore. Les premiers travaux d'instrumentation ont montré que cette matière jetée pouvait être capturée [35], et la génération actuelle d'agents prouveurs consomme les échecs comme négatifs d'entraînement ou comme invites de réparation [41, 8]. Mais dans tous les systèmes que nous connaissons, l'échec lui-même reste un artefact *non vérifié* : un message de compilateur, le diagnostic que le modèle porte sur lui-même, une trajectoire jugée. Rien ne garantit que le mur enregistré était réel, que sa cause déclarée est la cause effective, ni que la recherche qu'il interdit est effectivement sans espoir.

Cet article prend la position inverse : **l'échec peut être certifié avec la même rigueur que le succès**. Dans notre système, une impasse est un objet portant un certificat vérifié par le noyau — par exemple une dérivation de l'absurdité à partir de l'hypothèse résiduelle qui a tué la route — accompagné d'un périmètre *calculé* énonçant exactement quels buts elle condamne. Une infidélité au texte source n'est pas un score d'alignement estimé mais une contradiction dérivée. Ce qu'un théorème suppose en silence ne se lit pas sur son nombre d'hypothèses : cela se mesure sur sa dérivation. Et le corpus de tels objets oriente de façon démontrable la recherche ultérieure : les routes certifiées mortes ne sont jamais payées deux fois, et un théorème révoqué, conservé avec son certificat, peut plus tard être réhabilité tel quel une fois sa théorie réparée.

Le cadre aiguise l'expérience. Nous travaillons dans un noyau LCF implémenté sur le système formel *propre* à Bourbaki — l'opérateur τ , ses assemblages abrégés, et le corps de critères que Bourbaki *démontre* sur les démonstrations au lieu de les poser comme règles — un formalisme qu'à notre connaissance aucune mécanisation antérieure n'habite (section 2). Ce que le noyau implémente, c'est la *notion* bourbakiste de théorie : tout nom portant un ensemble fini d'axiomes explicites y passe sans rien changer, et le corpus en frappe soixante — ce qui est précisément pourquoi un théorème peut consommer en silence des axiomes que son énoncé ne mentionne jamais. L'oracle est exact, de sorte que chaque concept du cadre a un sens décidable ou dérivable ; et le corpus est assez petit pour être audité complètement, tout en étant assez riche pour qu'en une semaine instrumentée le cadre ait trouvé et réparé trois défauts de transcription d'axiome (deux en dérivant une contradiction), dissous trois murs fantômes (sur les neuf que son corpus enregistre), révoqué un théorème vacueux puis réhabilité celui-ci par décharge, exposé 53 axiomes de dette

invisible derrière un théorème « sans hypothèse », et fini avec la suite complète de 3 909 tests au vert (section 6). Il s’agit délibérément du *dernier kilomètre* de la formalisation : l’écart entre un corpus qui se contente de construire et un corpus fidèle à sa source, honnête sur ses dettes et instrumenté sur ses échecs — et c’est ce kilomètre instrumenté, non tel ou tel théorème, que cet article mesure.

Contributions.

1. La première mécanisation, à notre connaissance, du formalisme propre de Bourbaki : τ , assemblages et critères C1–C62, comme corpus vivant et testé (section 2).
2. Des objets d’échec certifiés à périmètre calculé, et la taxonomie E1–E7, chaque classe étant instanciée par un cas réel et mesuré (section 3).
3. La mesure de dette $Ax(D)$ — avec l’écart mesuré entre hypothèses déclarées et axiomes consommés — et une trichotomie opérationnelle des hypothèses ouvertes dont nous n’avons trouvé la troisième branche (l’indépendance) nulle part ailleurs, y compris un résultat négatif sur son tentant raccourci syntaxique (section 3).
4. La fidélité mécanisée : l’infidélité comme verdict *dérivé* contre une source imprimée préexistante, deux défauts détectés et réparés de cette façon, la guérison elle-même prouvée, et le coût mesuré — deux énoncés qui n’étaient démontrables qu’à travers l’incohérence (section 4).
5. Un détecteur vectoriel sans entraînement pour les axiomes jumeaux, calibré sur des paires de statut connu, et les retours tracés instance par instance de la boucle guidée par le corpus (section 5).

La section 7 situe chaque contribution face à un balayage systématique et adversarial de l’état de l’art ; la section 8 énonce ce qu’une étude à opérateur unique et oracle exact peut, et ne peut pas, revendiquer.

2 Contexte : le système formel de Bourbaki et le noyau

2.1 Un formalisme que personne n’habite

Dans la *Théorie des ensembles*, les quantificateurs n’existent pas comme primitifs. Ce sont des *abréviations* construites à partir de l’opérateur de choix de Hilbert. Notons R une relation, x une lettre, et A un *assemblage* : une succession finie de signes — les quatre signes logiques $\square, \tau, \vee, \neg$, les lettres, et les signes spécifiques de la théorie — dont certaines paires sont jointes par des *liens* (E I.14, l. 11–16). Alors

$$(\exists x)R := (\tau_x(R) \mid x) R,$$

où $(A \mid x)R$ est la notation de Bourbaki pour l'assemblage obtenu en substituant A à chaque occurrence de la lettre x dans R — ailleurs écrite $R[A/x]$. Comme $\tau_x(R)$ contient lui-même une copie complète de R , déplier un quantificateur recopie la formule dans elle-même ; les quantificateurs imbriqués croissent multiplicativement à chaque niveau. Les conséquences sont célèbres : entièrement développé en signes primitifs, l'entier 1 de Bourbaki occupe $4,5 \times 10^{12}$ symboles (Mathias), environ $2,4 \times 10^{54}$ dans l'édition de 1970 (Solovay). Les assemblages ne sont d'ailleurs ni des chaînes ni des Les liens portent la seconde difficulté : chacun attache une occurrence du signe $\square$ — le carré, qui marque la place qu'occupait une variable liée — au τ qui la lie. Un assemblage est donc un graphe, ni une chaîne ni un arbre, et il n'a de syntaxe native dans aucun assistant de preuve. Enfin, puisque la variable liée disparaît dans les liens, le système n'a pas de α -conversion : la substitution est triviale par construction, et c'est précisément la propriété que cite Grimm lorsqu'il explique pourquoi Gaia formalise le *contenu* de Bourbaki au-dessus de la logique propre de Coq et traite le chapitre I — assemblages, τ , critères de déduction — comme une simple description. À notre connaissance (section 7), aucune mécanisation antérieure n'habite le formalisme lui-même ; c'est pourtant exactement là que vit la métathéorie de Bourbaki : les critères sont des théorèmes *sur* les théories — dont C62, la licence de toute définition par récurrence, sur laquelle le corpus s'appuie de bout en bout.

2.2 Le noyau : l'habiter quand même

Le noyau est écrit en Python pur, dans le style LCF.

Définition 1 (Termes et relations abrégés). *Les ensembles $\mathcal{T}$ des termes et $\mathcal{R}$ des relations sont définis par induction mutuelle, exactement comme le noyau les représente :*

$$\begin{aligned} T &::= x \mid s(T_1, \dots, T_n) \mid \tau_x(R) && (\text{lettre, signe spécifique, choix}) \\ R &::= (T = U) \mid (T \in U) \mid \neg R \mid (R \vee S) \mid (\exists x)R && (\text{les cinq formateurs de relation}) \end{aligned}$$

où x parcourt les lettres, s les signes spécifiques de la théorie, et $T, U \in \mathcal{T}$, $R, S \in \mathcal{R}$. Ces huit constructeurs sont les seuls : $\forall$, $\wedge$, $\Rightarrow$ et $\Leftrightarrow$ sont des abréviations bâties sur eux, au sens de Bourbaki comme dans le code.

Définition 2 (Objet théorème). *Notons $\mathcal{P}_{\text{fin}}(\mathcal{R})$ l'ensemble des parties finies de $\mathcal{R}$, et $\mathcal{J}$ l'ensemble des étiquettes de justification : le nom de la règle du noyau appliquée et, pour la règle d'axiome, la théorie dont il provient — ce qui est précisément ce qui rend observable la dette de la section 3. Un théorème est un élément*

$$\theta \in \mathcal{P}_{\text{fin}}(\mathcal{R}) \times \mathcal{R} \times \mathcal{J}.$$

Ses trois projections sont notées H , C et j :

- $H(\theta) \subseteq \mathcal{R}$, *fini* — les hypothèses dont θ dépend encore ;

- $C(\theta) \in \mathcal{R}$ — la conclusion que θ affirme ;
- $j(\theta) \in \mathcal{J}$ — la justification, c'est-à-dire la règle qui a produit θ .

Le théorème est clos lorsque $H(\theta) = \emptyset$. L'égalité ne porte que sur les deux premières projections,

$$\theta = \theta' \iff H(\theta) = H(\theta') \text{ et } C(\theta) = C(\theta'),$$

de sorte que la justification enregistre comment un théorème a été obtenu, non ce qu'il affirme.

Exemple 1 (Un théorème, de bout en bout). Prenons la relation $x \in E$: par la définition 1, elle est bâtie par le formateur $\in$ à partir de deux lettres. La supposer donne le théorème

$$\theta_1 : \quad H(\theta_1) = \{x \in E\}, \quad C(\theta_1) = (x \in E), \quad j(\theta_1) = \text{hypothèse},$$

qui n'est *pas* clos — il n'affirme sa conclusion que sous sa propre supposition. Décharger cette supposition par la règle de déduction donne

$$\theta_2 : \quad H(\theta_2) = \emptyset, \quad C(\theta_2) = ((x \in E) \Rightarrow (x \in E)), \quad j(\theta_2) = \text{déduction},$$

qui est clos. Rien n'a été démontré sur E en chemin : ce que le second objet enregistre, c'est que l'hypothèse est passée de la gauche du signe $\vdash$ dans la conclusion. Ce déplacement est toute la *décharge*, et la section 3 repose sur le fait que c'est la seule chose qu'un compte d'hypothèses reflète.

Les objets théorème sont opaques : ils ne sont constructibles que par les règles du noyau, et aucun autre code du corpus ne peut en fabriquer un.

Les démonstrations de Bourbaki n'utilisent qu'une *seule* règle : une démonstration est une suite dont chaque relation est un axiome — explicite, ou instance d'un schéma — ou se déduit de deux relations antérieures, R et $R \Rightarrow S$ (E I.22, l. 16–25). Tout le reste, y compris le critère de déduction et la généralisation, il l'établit comme *critères* : des métathéorèmes sur les démonstrations, démontrés une fois pour toutes.

Notre noyau s'en écarte sur deux points, et les deux élargissent délibérément la base de confiance. Il prend le critère de déduction et la généralisation comme règles *primitives* plutôt que de les redériver à chaque usage — le code les marque comme primitives de confiance, non dérivées — et il porte l'ensemble d'hypothèses H dans l'objet théorème, là où Bourbaki passerait à une théorie plus forte. Au-delà de ces deux écarts, les règles sont le détachement, les schémas S1–S7 et les axiomes explicites.

Les schémas ne forment pas une liste plate, et la théorie des ensembles n'est pas toute l'histoire. Bourbaki bâtit les théories en *tour*, chaque étage ajoutant ses propres axiomes *implicites* : S1–S4 appartiennent aux théories *logiques* (E I.25), S5 aux théories *quantifiées* (E I.33), S6 et S7 aux théories *égalitaires* (E I.38). La théorie

des ensembles est alors la théorie égalitaire qui ajoute le signe d'appartenance et ses propres axiomes *explicites*, et le corpus est organisé le long de cette tour plutôt qu'autour de son dernier étage. C'est pourquoi l'invariant que nous vérifions compte 22 axiomes *explicites* : tout ce qui est en dessous est hérité sous forme de schémas, et un théorème peut en consommer sans que le compte bouge — l'écart dont la section 3 fait une mesure.

Les critères sont stratifiés de la même façon, et ce ne sont pas des règles du noyau. Chacun est un métathéorème sur les démonstrations *dans une théorie*, démontré à l'étage où il devient énonçable — la plupart parmi les théories logiques, la généralisation (C27) parmi les quantifiées, et les derniers seulement une fois la théorie des ensembles disponible. De toute la série, le noyau n'en prend que trois comme primitives : le détachement C1, la déduction C14, la généralisation C27. Les autres sont dérivés, et bon nombre le sont à l'intérieur même du corpus — ce qui fait de « nous habitons C1–C62 » une affirmation sur une bibliothèque testée, et non sur une intention de conception.

Deux décisions de conception rendent le formalisme praticable :

Arbres abrégés, développement comme justification. Construire l'axiome A1 d'extensionnalité par τ -développement complet épuise la mémoire — une **MemoryError** reproductible à la demande et journalisée, fidèle à la remarque de Bourbaki lui-même sur la nécessité pratique des abréviations. Le noyau représente donc $\forall/\exists$ comme abrégiateurs du premier ordre au niveau de l'arbre ; le τ -développement reste la *justification* des règles, non la représentation à l'exécution.

Ce qui reste non déplié, c'est l'*abréviation quantificateur*, pas τ . L'opérateur de choix est un constructeur de termes primitif du noyau, régi par le schéma S7 de Bourbaki lui-même (E I.38, l. 22–24) : pour toutes relations R et S et toute lettre x ,

$$(\forall x)(R \Leftrightarrow S) \Rightarrow \tau_x(R) = \tau_x(S).$$

L'opérateur est habité dans tout le corpus. Pour un graphe f , c'est-à-dire un ensemble de couples, et un objet x quelconque, la valeur $f(x)$ est le terme $\tau_y((x, y) \in f)$ (E II.13). Le terme est bien formé quels que soient f et x ; il ne dénote ce qu'on attend d'une valeur que si f est fonctionnel et si x appartient à son domaine. Garder cet écart visible, au lieu de le masquer derrière une discipline de typage, est ce qui fait échouer une preuve bruyamment plutôt qu'en silence — et la section 3 porte pour l'essentiel sur ce que cela rapporte. Les projections d'un couple, les cardinaux et chaque témoin canonique que nous construisons à la place d'un appel au choix sont des τ -termes de la même façon. C'est là que le système s'écarte des assistants qui prennent $\forall/\exists$ pour primitifs logiques et ne portent aucun opérateur de choix dans leur noyau. Cela se paie : puisque $\exists$ est un nœud primitif et non une τ -abréviation à l'exécution, quelques résultats démontrés au niveau τ — dont la réflexivité de l'égalité — sont transportés au niveau abrégé comme primitives de confiance. C'est le troisième et dernier élargissement de la base de confiance, et le code marque chacun d'eux.

Le coût résiduel est réel et mesuré : les termes cardinaux sont des τ -termes, construire des objets dépendant de $\mathbb{N}$ coûte des minutes par process, imprimer un terme cardinal n'est jamais tenté (son développement est intraitable en pratique), et une seule instanciation de variables vers des termes clos fait passer une formule de 9 388 à 86 598 caractères. Ce coût est une propriété du système formalisé, non de l'implémentation ; c'est aussi, comme le montre la section 5, la raison pour laquelle la mise en cache et la vectorisation comptent.

Pas d' α -identification. Le noyau n'identifie pas les α -variantes : deux formules α -équivalentes sont des objets distincts, comparés par un prédicat dédié et convertis par un pont certifié explicite. Cette sévérité est ce qui rend la dérive (section 3) détectable tout court — et ce qui fait des noms de liants codés en dur un piège récurrent et mesurable.

Théories dédiées. Au-delà des 22 axiomes explicites de la théorie de référence, le corpus frappe de petites théories ad hoc : 60 fabriques à l'heure où nous écrivons, dont 19 paramétriques. Chacune provient du schéma de sélection de Bourbaki, qui autorise à nommer l'ensemble des éléments d'un ensemble donné qui satisfont une relation donnée, et à doter ce nom de son propre axiome caractéristique. Le procédé est légitime et inévitable, et il a une conséquence que personne ne mesure — la dette invisible de la section 3 — et un coin réellement dangereux : les objets théorème ne portent aucune trace de leur théorie, si bien que le noyau ne peut pas voir qu'une variable libre d'un axiome ad hoc est une *constante* de cette théorie au moment de généraliser.

Le corpus à l'heure où nous écrivons : 4 221 tests collectés re-dérivant à chaque passage ses théorèmes, 2 234 notions ancrées au livre imprimé à la granularité à la granularité de la page, et un journal de 232 événements d'échecs certifiés — l'objet d'étude de cet article.

Sa répartition mérite d'être dite, car le titre du livre invite à une image fausse. Les 2 181 notions ancrées au moment de la campagne rapportée en section efsec:case-study se distribuent sur la tour et sur les chapitres qu'elle porte :

§I.1	assemblages, constructions formatives	82
§I.2	démonstrations, critères, noyau	133
§I.3	théories <i>logiques</i>	5
§I.4	théories <i>quantifiées</i>	32
§I.5	théories <i>égalitaires</i>	22
Ch. II	les ensembles proprement dits	720
Ch. III	ensembles ordonnés, cardinaux, entiers	1 002
Ch. IV	structures	185

Deux lectures importent ici. D'abord, l'étage ensembliste représente environ un tiers du corpus et la plus grosse part revient au chapitre III, tandis que la revendication de nouveauté — habiter τ , les assemblages et les critères — porte sur le chapitre I : *Théorie des ensembles* est le nom du livre, qui érige la tour entière, et

non celui d'un étage privilégié. Ensuite, les trois étages de théories ne paraissent minces que parce que le corpus est classé par *nature* et non par étage : les critères démontrés dans les théories logiques sont comptés au §I.2 avec les autres critères, et c'est là qu'un lecteur du dépôt les trouvera.

3 L'échec certifié : définitions, taxonomie, objets

Dans toute la suite, une *théorie* $T = (nom, A_T)$ est un nom accompagné d'un ensemble fini $A_T \subseteq \mathcal{R}$ de relations, ses axiomes *explicites*. Ses axiomes implicites — les schémas S1–S7 de la tour de la section 2 — sont délibérément absents du couple : toute théorie de ce corpus repose sur le même étage égalitaire, si bien que les schémas sont des règles du noyau offertes à toutes plutôt que des données portées par chacune. Nous notons T_0 la théorie de référence, de sorte que A_{T_0} est constitué des 22 axiomes explicites de l'étage ensembliste ; les théories ad hoc frappées par sélection sont d'autres T , le plus souvent à un seul axiome, et c'est leur invisibilité dans l'énoncé d'un théorème que la dette ci-dessous mesure. Enfin θ est un objet théorème au sens de la définition 2, de projections $H(\theta)$, $C(\theta)$, $j(\theta)$.

Nous écrivons $\Gamma \vdash R$, pour un $\Gamma \subseteq \mathcal{R}$ fini, lorsque le noyau peut construire un théorème θ tel que $C(\theta) = R$ et $H(\theta) \subseteq \Gamma$; $A_T \vdash R$ autorise en outre les axiomes de T à entrer par la règle **axiome**, et $\vdash R$ seul signifie $\emptyset \vdash R$, un théorème clos. C'est un énoncé sur ce que le noyau *peut bâtir* : chaque $\vdash$ de cet article est donc témoigné par un objet, jamais affirmé.

Une *route* vers un but est une dérivation tentée de ce but, et le *résidu* d'une route est l'ensemble des hypothèses que porte encore le théorème auquel elle aboutit — c'est-à-dire $H(\theta)$ pour le θ que la route a produit. Un but a en général plusieurs routes, et une même hypothèse peut être ouverte sur l'une et close sur l'autre ; c'est pourquoi les verdicts ci-dessous portent sur une hypothèse *sur une route*, et non sur une hypothèse tout court.

Le système de Bourbaki n'a pas de faux primitif ; nous fixons le témoin clos $\perp := (\emptyset \in \emptyset)$, puisque $\vdash \neg(\emptyset \in \emptyset)$ est clos depuis l'axiome de l'ensemble vide.

3.1 La dette : ce qu'une dérivation suppose réellement

Définition 3 (Consommation et dette). *Appelons dérivation D d'un théorème θ la suite finie d'applications de règles du noyau qui l'a produit. L'une de ces règles est*

$$\text{axiome}(T, \alpha), \quad T \text{ une théorie, } \alpha \in A_T,$$

qui rend le théorème clos affirmant α et refuse tout α hors de A_T : c'est le seul chemin par lequel un axiome peut entrer dans une dérivation, et c'est ce qui rend observable ce qui suit. Posons

$$Ax(D) := \{(T, \alpha) \mid \text{la règle } \text{axiome}(T, \alpha) \text{ apparaît dans } D\}.$$

La dette de θ dérivé par D est

$$Dette(\theta) := H(\theta) \cup \{\alpha \mid (T, \alpha) \in Ax(D), T \neq T_0\},$$

et l'invariant réel est $Ax(D) \subseteq \{T_0\} \times A_{T_0}$.

Ces deux lignes méritent d'être lues en mots. La première dit que ce sur quoi θ s'appuie réellement, c'est ce qu'il suppose encore, *plus* tout axiome que sa dérivation est allée chercher ailleurs que dans la théorie de référence — et que seule la première moitié en est visible dans son énoncé.

La seconde est la forme honnête de « la théorie a 22 axiomes ». Cet invariant familier est une propriété d'un *objet* théorie : on compte les axiomes de T_0 et l'on trouve 22, aujourd'hui et tous les jours, quoi que l'on démontre. L'invariant ci-dessus est une propriété d'une *dérivation*, et il dit quelque chose de bien plus fort : que cette preuve-là ne devait rien hors de la théorie de référence. Un corpus peut satisfaire le premier partout et violer le second constamment — et c'est cet écart que mesure le reste de cette section.

Le compte d'hypothèses d'un théorème n'enregistre que ce que la *décharge* a laissé derrière elle — la règle de déduction du noyau retire une hypothèse en la transformant en implication, et ce qui survit à ce traitement est $H(\theta)$. Il n'enregistre rien de ce que la dérivation est allée chercher en chemin. La dette, si : elle garde les hypothèses et leur ajoute tout axiome puisé dans une théorie autre que T_0 , et rien dans l'énoncé ne borne cet ajout.

Notre instance mesurée est un théorème du corpus annoncé « clos, 0 hypothèse » — le bon ordre de $\mathbb{N}$. Sa dérivation a été mesurée appliquant la règle **axiome 67 fois, dont 53 sur des théories ad hoc**. Son énoncé comme le compte global d'axiomes, resté 22 tout du long, étaient aveugles aux 53.

L'instrument est un observateur placé autour de la règle **axiome** : le noyau n'est pas modifié, et chaque entrée dans la règle enregistre le couple (T, α) . Cela rend un mode de défaillance intrinsèque, et il vaut la peine de l'énoncer. Plusieurs fonctions de preuve du corpus sont mémorisées ; au second appel dans le même process, le théorème en cache est rendu sans que son corps s'exécute, la règle n'est donc jamais franchie et l'observateur voit un $Ax(D)$ vide pour une dérivation qui consomme bel et bien des axiomes. Mesuré, cela sous-compte jusqu'à 62 %. Une mesure n'est donc valide qu'en process frais et en première position — et le corpus porte un test qui *exhibe* ce faux négatif au lieu de le taire.

3.2 Vacuité, dérive, murs fantômes

Définition 4 (Vacuité). θ est vacueux dans une théorie T , ce qu'on note $Vac_T(\theta)$, lorsque $A_T \cup H(\theta) \vdash \perp$. La vacuité est donc relative à T : un même théorème peut être vacueux dans une théorie et sain dans une théorie plus forte, ce dont la réhabilitation ci-dessous tire précisément parti.

Un théorème peut être parfaitement dérivé et pourtant sans valeur : la correction (*soundness*) est une propriété de la dérivation, la vacuité une propriété de la classe des modèles. Notre instance mesurée : $0! = 1$ (route Déf. 2) a été démontré sous $\mathcal{H} := (\forall G)(G \in \prod(u, \emptyset) \Rightarrow \text{Gr}(G))$, puis $\{\mathcal{H}\} \vdash \perp$ a été dérivé — le théorème a été révoqué. Fait crucial, il a plus tard été *réhabilité tel quel* : après la réparation d’axiome de la section 4, $\mathcal{H}$ est devenu un théorème clos et le squelette de preuve identique s’est re-dérivé, hypothèse déchargée. Un théorème vacueux n’est pas un théorème faux ; c’est un théorème qui attend sa théorie.

Définition 5 (Dérive). *Soit $C^* \in \mathcal{R}$ la conclusion visée de θ : la relation que θ est censé avoir, écrite d’après l’énoncé du livre dans un fichier de test qui ne partage aucun code avec le module qui démontre θ . Alors*

$$\text{Derive}(\theta, C^*) \iff \theta \text{ se construit, est clos, passe ses tests, et } C(\theta) \neq C^*$$

en tant que relations — inégalité syntaxique, non échec.

L’indépendance de C^* est tout l’enjeu. Un test qui compare la conclusion de θ à une expression bâtie par le *même* module compare une chose à elle-même : changez le module et les deux côtés bougent ensemble, le test reste vert et le théorème devient en silence un autre théorème. La dérive est donc invisible au noyau, puisque rien n’est faux, et invisible à tout test qui n’est pas ancré indépendamment.

Instance mesurée : après un changement d’axiome, un théorème du corpus se construisait toujours et restait clos tandis que sa conclusion passait de 6 908 à 8 592 caractères ; son test n’assertait que la clôture et serait resté vert. Deux règles en découlent, et nous les appliquons : les cibles sont reconstruites hors du module et comparées syntaxiquement, et les ensembles d’hypothèses sont comparés par égalité exacte d’ensembles, jamais par cardinalité.

3.3 La trichotomie des hypothèses ouvertes

Définition 6 (Trichotomie). *Pour une hypothèse ouverte h portée par une route sur T : h est déchargeable ssi $A_T \vdash h$; réfutable ssi $A_T \vdash \neg h$ (alors tout θ portant h est vacueux) ; indépendante sinon — aucune quantité de recherche de preuve ne la fermera, et les seuls coups légaux changent la théorie — comme à la figure 3.*

Les trois classes se sont produites, mesurées, en une seule semaine : $bo(\leq, \mathbb{N})$ — déclaré « résidu irréductible » pendant des semaines — est déchargeable (clos, 0 hypothèse) ; $\mathcal{H}$ ci-dessus est réfutable ; le pont famille-valeur $X_i = f(i)$ est classé indépendant de A_{T_0} . Le quatrième état épistémique, *inconnu*, est une dette de mesure et non un mur : le re-classifier après chaque correctif d’infrastructure a éliminé neuf murs fantômes dans notre corpus.

Proposition 1 (Un résultat négatif). *Le critère syntaxique « un symbole de h n’est contraint par aucun axiome de T_0 » n’est pas un test suffisant d’indépendance.*

hypothèse ouverte	rencontrée sur	verdict	issue
$bo(\leq, \mathbb{N})$	la route C62-existence	déchargeable	déclarée irréductible, prouvée close ensuite
$\mathcal{H}$	la route du cas 0	réfutable	source de la vacuité ; théorème révoqué
H_2, H_3	le pas de récurrence	déchargeable	tombées avec la réparation de la sec. 4
H_W, H_N	le pas de récurrence	indépendantes	aucune recherche ne les ferme ; seule la théorie change

Table 1: La frontière du front, agrégée sur ses routes plutôt que prise sur un instantané unique du journal. Le résidu mesuré du pas de récurrence était $\{n \in \mathbb{N}, H_2, H_3, H_W, H_N\}$, et la trichotomie l’a scindé. Chaque ligne est un cas mesuré, et chaque échec est enregistré comme objet certifié.

Contre-exemple, mesuré : $\text{symboles_libres}(bo(\leq, \mathbb{N})) \neq \emptyset$, et pourtant l’hypothèse est prouvablement close. Le critère est une *indication* (un argument de réinterprétation est disponible) et ne doit être appliqué qu’après l’échec d’un prouveur ; appliqué en premier, il aurait fabriqué un mur fantôme de plus.

L’asymétrie interne à la trichotomie est essentielle. *Déchargeable* et *réfutable* sont attestées par des objets du noyau ; *indépendante* ne l’est pas, et ne peut pas l’être : c’est l’*absence* des deux témoins. Le classifieur ne renvoie donc *indépendante* qu’après l’échec d’un prouveur et lorsque l’indication des symboles libres tient — un ordonnancement des preuves, non une preuve. Indépendance et *inconnu* se distinguent opérationnellement, par la force du prouveur qui a échoué, jamais par certification. C’est la seule branche de la trichotomie dont le verdict est révisable, et le corpus l’enregistre comme telle.

3.4 Les objets d’échec et leurs conditions de validité

Définition 7 (Échec certifié). *Echec* = $(P, \kappa, c, \text{rebroussement}, \text{perimetre})$ — nous gardons les noms français du dépôt, *Echec* et *Mur*, pour coller au code. Ici P est le but qui était visé, $\kappa \in \{E1, \dots, E7\}$ sa classe d’échec, c un objet du noyau certifiant cette classe, *rebroussement* le changement énoncé qui évite d’y retomber, et *perimetre* l’ensemble calculé des buts que l’échec condamne. *verifier* accepte ssi c correspond à κ : pour $E2$ (vacuité), $C(c) = \perp$ et $H(c) \subseteq$ le résidu de la route ; pour $E5$ (fantôme), c est clos et $C(c)$ est le résidu déclaré ; etc. Un échec dont le certificat échoue à la vérification est rejeté du corpus.

Définition 8 (Mur). *Mur* = $(\text{condition}, \text{predicat}, c)$: tant que *condition* n’est pas réparée, tout but satisfaisant *predicat* est condamné, et *predicat* calcule le périmètre au lieu de l’affirmer.

Instance mesurée : le témoin de réfutation derrière $\mathcal{H}$ code en dur l’index vide, si bien que le prédicat du mur n’atteint prouvablement que les produits sur un index littéralement vide — $H2$ (index $I \cup \{j\}$) et $H3$ (index variable) ont été *prouvées hors d’atteinte*, et exactement un fichier a été révoqué. La figure 1 montre un tel mur en place, avec le verdict de chaque hypothèse qu’il laisse ouverte.




Figure 1: Un mur réel : la dernière équation ouverte du front factorielle. Les boîtes pleines sont des objets du noyau, les boîtes en tirets les hypothèses que la chaîne de dérivation laisse *ouvertes*, et la barre est le mur qui les sépare du but. La couleur d’une boîte est son verdict de trichotomie, détaillé au tableau 1.

4 Fidélité mécanisée : quand le corpus réfute le livre

4.1 La discipline d’ancrage et le verdict d’infidélité

Chaque notion formalisée porte un ancrage lisible par la machine `@livre Ch.X §s.ss Type.n | E X.pp L.a-b | PDF p.n` qui la relie à la source imprimée (2 234 notions ancrées à l’heure où nous écrivons). L’ancrage a deux champs de fiabilité inégale, et nous les séparons parce que nous les avons mesurés.

La page est sûre ; l’intervalle de lignes ne l’est pas uniformément. C’est le champ « page » qui porte les résultats de couverture ci-dessous : zéro ancrage non conforme, et cinq parties du livre déclarées complètes sur leur intervalle. L’intervalle de lignes est plus faible, et nous l’avons découvert en auditant nos propres ancres contre le livre. Sur la page E II.22 — 36 lignes imprimées, comptées à la main — la Définition 1 occupe les lignes 15–18 et la Définition 2 les lignes 27–30, tandis que leurs ancres disent L.31–36 et L.49–53 ; le second dépasse la page. Or la ligne 53 de notre *transcription* L^AT_EX de cette page est exactement l’en-tête de la Définition 2 : ces deux ancres indexent la transcription, pas le livre. Sur la page E II.7, l’inverse — l’ancrage suit la ligne imprimée à un petit décalage près et ne correspond pas du tout à la transcription. Au moins deux conventions coexistent dans le corpus.

classe	définition	certificat valide	cas mesuré
E1 dérive	$C \neq C^*$	comparaison syntaxique	<i>membre_but</i> (6 908 $\rightarrow$ 8 592 car.)
E2 vacuité	$\{h\} \vdash \perp$	théorème de conclusion $\perp$	$\mathcal{H} / 0! = 1$ révoqué
E3 impasse	aucune continuation ne clôt	élague les extensions	la route « $n-1$ » (terme de différence opaque), év. 84–85
E4 dette	$Ax(D) \not\subseteq \{T_0\} \times A_{T_0}$	mesure en process frais	<i>n_bien_ordonne</i> : 53 axiomes étrangers
E5 fantôme	résidu déjà prouvable	théorème clos = résidu	<i>bo</i> ($\leq, \mathbb{N}$), 9 cas au total
E6 infidélité	$A_{T_0} \cup \Phi \vdash \perp$	dérivation close + ancre source	deux défauts d'axiome (sec. 4)
E7 mesure	la sonde a menti	contre-mesure	sonde à noms devinés (faux négatif)

Table 2: La taxonomie des échecs. Chaque classe est instanciée par un cas réel de la semaine instrumentée, vérifié par le noyau.

Mesuré sur les 1 992 ancrages portant un intervalle de lignes : **12,2 % finissent au-delà de la ligne 36**, soit environ une page pleine de cette édition, et ne peuvent donc pas être des références à des lignes imprimées ; le maximum est 63. Le gros de la distribution a la forme d'une page imprimée, avec une queue qui n'en a pas.

Nous revendiquons donc la traçabilité à *la granularité de la page*, qui est ce que les instruments de couverture consomment réellement, et nous présentons les intervalles de lignes intra-page comme une *heuristique* de localisation du matériel non formalisé plutôt que comme une mesure certifiée. C'est une revendication plus faible que celle que cet article portait en brouillon, et la raison de la consigner ici est que c'est la thèse même de l'article retournée contre lui : aucun test d'un dépôt vérifié par noyau n'attrape un ancrage qui décrit mal le livre, et les nôtres sont restés inexaminés jusqu'à ce que nous ouvrons les pages. Soit Φ la transcription des énoncés numérotés du livre. La fidélité elle-même — « $\varphi(b)$ signifie b », pour un énoncé b du livre et sa formalisation $\varphi(b)$ — relie du texte à des formules et n'est pas formalisable ; sa négation, si :

$$Infid \iff A_{T_0} \cup \Phi \vdash \perp.$$

Infid est semi-décidable : on peut toujours *trouver* une infidélité, jamais certifier son absence — c'est pourquoi notre audit est un processus permanent plutôt qu'un pourcentage de couverture. Deux conséquences de la discipline sont mécanisables gratuitement : deux ancres citant la même phrase à des lignes différentes exposent une erreur par simple comparaison (deux cas réels trouvés et corrigés) ; et un numéro de ligne recopié se propage — une valeur fausse a été trouvée répliquée verbatim sur cinq sites.

L'autoformalisation récente à l'échelle du projet enregistre elle aussi la provenance au niveau de l'empan ; l'état de l'art, M2F [44], impose ensuite la fidélité des énoncés « par un *audit manuel* relié à la provenance » (p. 8). Notre écart est exactement là : le verdict d'infidélité est *dérivé*. Les deux défauts ci-dessous ont été établis en

prouvant une contradiction dans le noyau, et les deux réparations ont été prouvées efficaces par l'impossibilité de la re-dérivée.

Un troisième défaut, trouvé la même semaine, a amorcé la méthode. L'axiome d'intersection avait été transcrit depuis le *Résumé des résultats* du livre (E R.19), dont l'univers de familles de *parties* rend $\bigcap_{\emptyset} = E$ légitime, plutôt que depuis E II.22, dont la Définition 2 exige $I \neq \emptyset$ (et dont la note de bas de page avertit que l'intersection non restreinte n'est pas collectivisante). La théorie de référence elle-même était donc incohérente. Le défaut a été localisé par preuve machine, son périmètre calculé à 34 sites, et réparé en restaurant la forme de sélection, en maintenant le compte d'axiomes à 22 ; l'incident était clos, suite au vert, avant que la moindre mesure de dette rapportée dans cet article ne soit prise. Les deux cas ci-dessous ont ensuite été trouvés *par* la discipline que ce premier incident a instituée.

4.2 Cas 1 : un axiome a perdu un conjoint

L'axiome de produit d'une famille avait perdu la borne que le livre impose aux graphes qu'il admet : pour une famille $(X_i)_{i \in I}$ d'ensembles indexée par I , un membre F du produit doit vérifier $F \subset I \times \bigcup_{i \in I} X_i$ (son frère, l'axiome d'exponentiation, avait gardé la sienne). Le corpus démontrait alors, à *zéro* hypothèse et pour toute famille u , à la fois $\{\emptyset\} \in \prod(u, \emptyset)$ et $\neg(\prod(u, \emptyset) = \{\emptyset\})$ — alors que E II.32 énonce que le produit vide a exactement un élément. Le corpus réfutait le livre. La correction n'a jamais été en cause : le noyau dérivait fidèlement depuis l'axiome qu'on lui avait donné ; c'est l'axiome qui n'était pas celui du livre. La réparation a restauré le conjoint *en position de tête* (un choix empirique : 18 tests cassés contre 33 pour la position de queue), a maintenu le compte d'axiomes à 22 (remplacement, non ajout), et a payé immédiatement : deux hypothèses portées pendant des semaines sont devenues des théorèmes, et le $0! = 1$ vacueux de la section 3 a été réhabilité par décharge. La figure 2 montre cette dérivation réhabilitée, la branche que le défaut bloquait étant marquée en vert.

4.3 Cas 2 : un terme a perdu un paramètre

Le terme $seg(E, x)$ — le segment initial déterminé par x — ne portait pas sa relation d'ordre : deux ordres différents produisaient le *même* terme, chacun avec son propre axiome caractéristique, tous deux acceptés à zéro hypothèse sous un unique nom de théorie. À partir de deux ordres concrets sur un ensemble à deux éléments, $\vdash \emptyset \in \emptyset$ se dérive en six pas de noyau. Une passe AST mécanique a ensuite généralisé la trouvaille : **21 constructeurs de termes perdent au moins un paramètre, 11 d'entre eux l'ordre**, avec une seconde contradiction dérivée pour les intervalles fermés.

Proposition 2 (Les gardes ne réparent pas les paramètres perdus). *Ajouter l'hypothèse « R est un ordre sur E » à l'axiome caractéristique laisse la contradiction dérivable :*




Figure 2: La dérivation réelle de $0! = 1$ (route Déf. 2) comme graphe à l'intérieur de la boîte-théorie. **Lecture** : chaque boîte est un objet du noyau — rangée du bas, les axiomes consommés ; au-dessus, les théorèmes dérivés ; la boîte à fond vert est le but. Une flèche de A vers B signifie « A est une prémisse du pas de noyau qui dérive B ». Les **flèches vertes épaisses** marquent la branche *indérivable* tant que l'axiome du produit était privé de son conjoint ; les **flèches grises fines**, les pas qui n'ont jamais dépendu du défaut. La dérivation entière est le dividende de la réparation.

deux ordres différents sur le même E satisfont tous deux la garde. Une condition perdue peut être restaurée par une garde (cas 1) ; un paramètre perdu, non — aucune condition ne répare un terme qui n'a pas d'emplacement pour l'accueillir.

Le remède structurel : le terme porte son graphe — $seg(G, E, x)$, pour un graphe G , un ensemble E et un point x — et l'axiome est $\forall$ -clos sur G également. Les quatre instances d'axiome α -distinctes s'effondrent en une seule formule close ; l'usine à théories perd son paramètre ; et la contradiction devient *structurellement indérivable* — il n'existe plus de mécanisme permettant de frapper deux axiomes incompatibles à propos d'un même terme. Effet de bord : la clôture supprime la variable libre qui avait permis au noyau de généraliser sur une *constante* de la théorie ad hoc (une condition de bord du C27 de Bourbaki que le noyau ne peut pas vérifier, pour la même cause racine que la dette invisible de la section 3 : les objets théorème ne portent aucune trace de leur théorie). La suite complète de 3 909 tests est au vert sous l'axiome réparé.

4.4 Le prix de la vérité : des contradictions porteuses

La réparation a eu un coût, et le nommer fait partie de la méthode. Deux théorèmes intermédiaires avaient éliminé le $\exists R_o$ de Zermelo *parce que* le terme de segment ne portait pas son ordre — leur prétendue « indépendance en R_o » était un artefact

du défaut. Après réparation, le noyau refuse à juste titre la généralisation ; les énoncés ont été reformulés sous forme R_o -close, et la perte est nommée : *Zermelo seul ne suffit plus* pour ces deux réductions — le bon ordre et la réalisation des segments par lui doivent être supposés ensemble. Les énoncés plus forts n'étaient démontrables qu'à travers l'incohérence. C'est le dual mesuré de la vacuité : la vacuité est un théorème né mort sous une hypothèse réfutable ; ici un théorème *meurt avec* le défaut qui le portait. Un audit d'incohérence doit donc regarder dans les deux sens : vers ce que le défaut rend faussement réfutable, et vers ce qu'il rend démontrable-mais-illégitime. La documentation locale avait affirmé l'indépendance de bonne foi — c'est la théorie ambiante qui mentait.

5 La boucle de guidage et la couche vectorielle

5.1 L'équation de guidage

Une politique nue propose $\pi(a \mid s)$; branchée sur le corpus, elle propose $\pi(a \mid s, M(s))$, où $M(s)$ retrouve les murs dont le prédicat couvre s , les couples de remède dont l'état enregistré ressemble à s , et les leçons applicables. $M(s)$ agit sur la direction de trois façons : il *interdit* (les murs certifiés élaguent les coups menant à des routes condamnées), *suggère* (un couple de remède dit : dans un état comme celui-ci, ce coup-là a échoué et celui-ci a marché), et *ordonne* (les prémisses les plus proches du but viennent en premier). La rétroaction se referme à trois échelles de temps : par coup, le noyau accepte ou refuse — le progrès halluciné n'existe pas ; par route, la frontière $Ouv(D)$ et les classes de trichotomie de ses hypothèses ouvertes donnent une estimation de valeur sans apprentissage (une route portant une hypothèse d'allure indépendante est condamnée quel que soit l'effort) ; par campagne, les problèmes du livre clos et la dette totale.

Les retours sont documentés instance par instance plutôt que moyennés : un squelette de preuve révoqué, conservé avec son certificat de vacuité, s'est re-dérivé tel quel une fois que l'axiome réparé a rendu son hypothèse déchargeable — une reconstruction complète évitée ; une route certifiée en impasse (un terme de soustraction opaque) nous a coûté une fois et jamais plus, l'agent suivant prenant directement la forme $succ(k)$ recommandée ; neuf murs fantômes ont produit la règle permanente *re-mesurer avant de croire*, après quoi aucune session n'a été perdue sur un mur inexistant. Les échecs de la boucle sont journalisés avec la même discipline (un pronostic de triage faux 21 fois sur 21 ; un dépassement de budget qui a produit le protocole de frugalité du projet), et la réserve de validité est énoncée à la section 8 : ce sont des instances tracées, non un effet contrôlé.

5.2 La couche vectorielle et le détecteur d'axiomes jumeaux

Les formules sont des arbres étiquetés. En notant $\ell_k(v)$ l'étiquette d'un nœud v après k tours et h une fonction de hachage, le raffinement de Weisfeiler-Leman

$$\ell_{k+1}(v) = h(\ell_k(v), \{\ell_k(u) : u \text{ fils de } v\})$$

haché dans $d=512$ compartiments pour $k \leq 3$ donne un plongement $\varphi(t)$ d'un terme ou d'une formule t , déterministe et sans entraînement, comparé par similarité cosinus — calculé en parcourant l'arbre abrégé, jamais en l'imprimant. Deux leçons de conception ont été apprises à la dure, et mesurées : une étiquette qui laisse tomber le nom du symbole fait s'effondrer des axiomes distincts ($\cos = 1,0000$ à tort), et un marcheur ignorant un attribut fils s'arrête à la profondeur un ; la règle corrective est que *les cartes de traits se valident sur des paires de similarité connue*, la discipline du test par mutation appliquée aux représentations. La calibration est livrée sous forme de tests. La paire incohérente d'axiomes *seg* mesure 0,9810 — reconstruite en fixture, le défaut lui-même ayant depuis été réparé, afin que le détecteur conserve un cas positif contre lequel être testé ; deux axiomes d'une même famille mesurent 0,8758 et une paire véritablement sans rapport 0,5415, si bien que $\theta = 0,90$ sépare avec marge des deux côtés.

Le détecteur signale alors

$$Twin(\alpha, \beta) \iff \tau(\alpha) \cap \tau(\beta) \neq \emptyset \wedge sim(\alpha, \beta) \geq \theta_{twin},$$

un terme caractérisé commun et des corps similaires, évalué sur les paires déjà retenues à $\theta = 0,90$. Il y a deux seuils et non un : θ choisit ce qui mérite un regard, $\theta_{twin} = 0,95$ tranche. La conjonction compte : la similarité la plus haute du balayage — un 1,0000 plein — relie deux copies d'une même formule, une théorie ad hoc portant encore l'axiome que la réparation de l'intersection avait depuis promu dans A_{T_0} . Son définiendum appartient au vocabulaire propre de T_0 et se trouve donc écarté de τ : aucun terme n'est partagé, aucune alerte n'est levée — alors que le score seul aurait déclenché la plus bruyante du corpus.

Définir $\tau(\alpha)$ a demandé un raffinement de plus, et c'est un faux positif qui l'a produit. Un premier critère prenait tout symbole propre à un axiome, et appariait donc l'axiome qui *définit* l'intervalle d'entiers avec un axiome qui se borne à *utiliser* comme borne. Deux axiomes qui mentionnent un terme ne sont pas en conflit ; seuls deux qui le définissent le sont. Le terme caractérisé est donc le définiendum — le membre gauche de l'équivalence définissante — et rien d'autre. La distinction n'est pas un détail d'implémentation : c'est elle qui sépare un score de similarité d'un verdict, et elle est restée invisible jusqu'à ce que le détecteur produise une alerte vérifiable à la main.

Le balayage vectorise 65 axiomes de 41 fabriques de théories — 43 axiomes de 40 théories dédiées, plus les 22 de T_0 lui-même, scannés comme témoins — en quelques secondes, renvoie 34 paires au-dessus de θ et *exactement un* jumeau (deux théories

caractérisant un même terme h_iso_max à 0,9911, en cours d’audit) ; 19 usines paramétriques sont sautées et signalées comme telles — elles sont la classe à risque elle-même, une usine paramétrique étant précisément le mécanisme qui a rendu *seg* incohérent. L’incohérence qui avait coûté une investigation de 95 minutes est désormais une requête de conformité permanente.

6 Étude de cas : une semaine instrumentée

Nous rapportons une semaine instrumentée (26 juillet – 2 août 2026) durant laquelle chaque mécanisme des sections 3–5 a été exercé sur des mathématiques vivantes — le chapitre factorielle de la *Théorie des ensembles* et sa machinerie amont.

défauts d’axiome trouvés & réparés	3 (un par preuve machine de l’incohérence de la théorie, deux par contradiction dérivée), tous réparés en maintenant le compte à 22, guérison prouvée par non-dérivabilité
affirmations de la documentation réfutées	~ 78 le premier jour d’audit ; un pronostic de triage du directeur mesuré faux 21/21 par la suite
murs fantômes dissous	3 cette semaine — neuf dans le corpus au total — des blocages déclarés, mesurés déchargeables ou déjà résolus
théorème vacueux	1 révoqué (hypothèse réfutable), plus tard <i>réhabilité tel quel</i> par décharge
énoncés affaiblis	2 , démontrables seulement à travers l’incohérence ; perte nommée (dual de la vacuité, sec. 4)
dette invisible mesurée	4 capstones : 53 / 57 / 9 / 82 instances d’axiomes étrangers derrière des comptes d’hypothèses déclarés de 0 / 10 / 4 / 7
constructeurs perdant des paramètres	21 signalés par une seule passe AST ; 11 perdent l’ordre ; 2 contradictions dérivées
suite de tests	3 850 → 3 909 collectés ; trois passages complets au vert sous réparations successives, final 3 909 / 3 909
journal d’événements certifiés	95 entrées à la fin de la semaine (37 antérieures à la semaine), chacune re-parsée et, le cas échéant, vérifiée par le noyau
économie du détecteur	investigation $\approx$ 95 min → requête quelques s

Table 3: La semaine instrumentée en chiffres. Chaque chiffre remonte à un événement journalisé et daté ; les totaux de tests ont augmenté au fil des trois passages au vert enregistrés — aucune suite n’a été mise en sourdine pour obtenir le vert.

Trois épisodes portent l’argument. *(i) Le cycle de réparation complet, deux fois.* Les deux défauts d’axiome ont parcouru la boucle entière — détecter par dérivation, localiser par périmètre mesuré, réparer structurellement, prouver la contradiction

indérivable, re-passer la suite entière —, démontrant qu’une théorie ambiante incohérente est un événement mesurable et réparable plutôt qu’une catastrophe. (ii) *Révocation et réhabilitation*. Le $0! = 1$ vacueux a été révoqué avec son certificat conservé ; la réparation a transformé son hypothèse réfutable en théorème ; le squelette identique s’est alors fermé sans résidu et a survécu à une passe adversariale (quatorze mutants authentiques tués, aucun par exception). Les objets d’échec ne sont pas des pertes sèches ; ce sont des actifs différés. (iii) *Le prix de la vérité*. La même réparation a affaibli deux énoncés acquis qui s’appuyaient sur le défaut — mesuré, nommé et conservé comme la meilleure preuve que la contradiction était vivante.

Opérationnellement, la semaine a aussi mesuré sa propre enveloppe : la photo de référence de la suite complète a tourné en 2 h 43 d’horloge à quatre workers ; les longues exécutions sont tuées par l’environnement aux alentours de la barre des 50 minutes, si bien que les suites sont découpées en sept zones avec persistance incrémentale des résultats ; et un dépassement précoce du budget d’agents a produit le protocole de frugalité sous lequel le balayage de l’état de l’art de la section 7 a plus tard renvoyé 69 références triées pour 237k tokens là où le premier fan-out de la semaine en avait brûlé 266k pour zéro résultat. Le harnais, lui aussi, fait partie de l’expérience.

Reproductibilité. Les comptes de tests cités dans l’étude de cas ci-dessus sont ceux de la semaine instrumentée et sont laissés tels que mesurés alors ; pour mémoire, la suite relancée intégralement le 20 août 2026 rend extbf4221 passed en 2 h 03 à douze workers avec exttt-dist loadfile. Nous rapportons les deux plutôt que de rétrofitter le récit avec un nombre postérieur.

Toutes les mesures ont été prises sur une seule machine Windows 11 : Python 3.13, pytest 9.0.3 avec `pytest-xdist`, `PYTHONIOENCODING=utf-8`, suites découpées par zone. L’instrument de dette n’est valide qu’à la première mesure d’un process frais (section 3) ; le balayage des jumeaux a tourné avec $K = 3$, $d = 512$, $\theta = 0,90$, $\theta_{\text{twin}} = 0,95$, et se reproduit par `python outils_ia/vecteurs/scan_jumeaux.py` — son plongement hache avec `blake2b` plutôt qu’avec le `hash` de Python, dont la randomisation par process rendrait irréproductible chacun des cosinus rapportés ici. Le corpus, le journal et chaque script cité ici sont livrés dans l’instantané du dépôt référencé en page de titre.

6.1 Seconde étude de cas : un énoncé ouvert sous instrumentation

Deux jours après la semaine rapportée ci-dessus (5–6 août), la même instrumentation a été tournée vers un énoncé *ouvert* : la conjecture de Goldbach, écrite sur l’arithmétique construite du corpus. Nous n’en rapportons ici que ce qui porte sur les thèses de cet article — que les défauts d’énoncé se *démontrent* et que la dette se *mesure*. Les réductions produites par l’épisode, et la mesure de la quantité d’arithmétique qu’elles contiennent, font l’objet d’un article compagnon ; les organes de découverte qu’il a exercés relèvent d’un troisième.

(i) *Deux défauts d'énoncé, démontrés dans le noyau.* La première rédaction de la conjecture disait « n pair et $n \neq 2$ ». Son antécédent est satisfait en $n = 0$ — démontré, clos : $\vdash \text{pair}(0)$ (témoin $k := 0$) et $\vdash \neg(0 = 2)$ — de sorte que l'énoncé affirmait que *zéro est somme de deux nombres premiers*. Réparé, il restait faux : « pair » contraint n à être un *cardinal*, non un entier, et l'antécédent est aussi satisfait par $n := \mathbb{N} + \mathbb{N}$, qui est infini — démontré de même, l'égalité avec l'ancien antécédent instancié étant vérifiée formule contre formule. La même faute — un quantificateur portant sur des ensembles alors qu'on le croit porter sur des entiers — avait été commise la veille sur le $(\forall d)$ de la primalité : c'est un *motif*, désormais consigné.

Fait notable : la variante bornée *démontrée* de l'énoncé portait la garde de finitude dès son premier jet, parce que sa preuve l'exigeait ; seul l'énoncé *non démontré* avait dérivé. **Démontrer force à nommer ses hypothèses ; énoncer ne force à rien.** Nous tenons cela pour l'observation la plus transférable de l'épisode, et c'est pourquoi l'audit de fidélité de la section 4 vise les énoncés qu'aucune preuve n'exerce actuellement.

(ii) *La dette, en trois nombres.* « Zéro hypothèse résiduelle » et « l'invariant des 22 axiomes tient » se lisent ensemble comme « ne dépend que des 22 » — faux au sens mesuré, puisque les axiomes entrent par la règle d'axiome et disparaissent du séquent (section 3). Mesuré en process frais sur la forme bornée en $n : \mathbf{0}$ hypothèse résiduelle ; **14** des 22 axiomes de référence consommés ; **53** formules étrangères — une seule règle, le critère C54 (le graphe d'une fonction définie par un terme, théorème chez Bourbaki, axiome de théorie dédiée ici), instanciée 52 fois, plus une instance de Knaster–Tarski. Un résultat honnête s'annonce avec les trois nombres ; le troisième dit ce qui reste à dériver.

Sur l'équivalence principale de l'épisode, la même mesure rend **0** ; **14** ; **73** — répartis sur 21 théories dédiées, la machinerie du bon ordre (Zorn, Zermelo, Bourbaki–Witt) entrant par le lemme « un minorant d'un fini est fini ». Lever une borne se paie en bon ordre : le saut de 2 à 21 théories *mesure* ce que coûte la généralité. La première mesure avait rendu zéro en une seconde — le théorème sortait d'un cache, et l'instrument est aveugle à ce qui n'est pas construit : la règle du process frais, écrite pour d'autres mesures, s'applique à elle-même.

Ce qui est différé. L'épisode a duré quatre jours et laissé le compte d'axiomes à 22. Sa production mathématique — une chaîne de réductions certifiées faisant converger la conjecture sur un seul objet, et la mesure, par paramétrisation du prédicat de primalité, que ces réductions ne contiennent aucune arithmétique — est rapportée séparément, de même que le travail des organes de découverte qu'il a exercés. Rien de tout cela n'approche la conjecture. Ce qui a sa place ici est la paire de résultats ci-dessus : un énoncé ouvert est un endroit particulièrement propice pour attraper un défaut de fidélité, précisément parce que rien ne le démontre.

7 Travaux connexes

Cette section condense un balayage systématique et adversarial (quatre pistes de recherche indépendantes, 57 requêtes, 69 références triées, les cinq menaces les plus proches lues intégralement) ; la méthode du balayage et ses tableaux complets sont dans le dépôt.

Les systèmes les plus proches. Goedel-Architect [8] est le voisin le plus immédiat : des graphes de plan dont les nœuds en échec portent l'un de *deux* diagnostics — énoncé-faux, appuyé par un contre-exemple vérifié par compilateur, ou preuve-trop-dure, close par un « forfait » structuré. Nos écarts sont au nombre de trois : leurs forfaits enregistrent où le prouveur *croit* que se trouve la lacune (prose non vérifiée) là où nos certificats sont des objets du noyau à périmètre calculé ; leur boucle vit à l'échelle d'une exécution là où notre corpus persiste et où les retours sont tracés instance par instance ; et leur diagnostic est binaire là où notre trichotomie a une troisième branche. AutoformBot [33], le système derrière la bibliothèque ATLAS, publie la *forme* de la boucle — des analyseurs de traces persistants maintiennent des « skill guides » que les workers doivent lire avant de réessayer — et un critère de succès délibérément non transitif ; nos revendications ne reposent donc pas sur la boucle mais sur la certification de ses maillons et sur la dette par dérivation. Les agents prouveurs auto-modifiants [23] co-évoluent avec un score de benchmark plutôt qu'avec un journal certifié.

Données d'échec et réparation de preuves. REPLica [35] a capturé des tentatives humaines ratées et des couples annulation-réparation à état constant — le format qu'adoptent nos événements de remède. La lignée de la vérification de programmes transforme les preuves ratées en artefacts structurés : un test exécutable dérivé d'un contre-exemple [13] avec une taxonomie de diagnostic à trois causes [31]. La réparation est désormais une industrie : par transformation [36], à l'échelle d'un jeu de données [34], conditionnée par le message d'erreur [10, 41], locale au plan [17]. Il existe des taxonomies d'erreurs pour les tentatives humaines [2], les incompatibilités de version [25] et les défauts de benchmark [5] — ce dernier étant le seul autre travail que nous ayons trouvé qui *certifie* les défauts qu'il rapporte. Aucun de ceux-ci ne certifie un échec de recherche dans le noyau, ne calcule son périmètre d'invalidation, ni ne le conserve lorsque aucune réparation n'existe.

Fidélité et Bourbaki. La provenance au niveau de l'empan vers les textes sources est désormais standard à l'échelle d'un projet [44, 6], et la certification de fidélité est un sujet actif en 2026 [28, 43] ; la différence décisive, argumentée à la section 4, est que le verdict de l'état de l'art est estimé ou manuel là où le nôtre est dérivé. L'audit de preuves [1] et la détection d'incohérences dans de grandes bases du premier ordre [37] poursuivent la correction d'une base pour elle-même, sans texte source ni guérison certifiée. Sur le formalisme : Gaia [11] formalise le

contenu de Bourbaki au-dessus de Coq et laisse le chapitre I décrit mais inhabité ; la pathologie de taille est classique [26] ; des noyaux LCF modernes existent en Python [47] et au-dessus de la théorie des ensembles standard [12], si bien que le véhicule n'est pas la nouveauté — c'est le formalisme habité qui l'est.

Réparation, révision et formation de théories. La réparation automatisée de théories est un programme établi [21, 22, 39], fondé sur la révision AGM [3] ; ses diagnostics sont heuristiques et ses remèdes validés empiriquement, non par un changement de dérivabilité dans un noyau. Un Lakatos computationnel existe [30] et l'exploration de théories découvre de vrais lemmes [15] ; les deux jettent leurs échecs. La réfutation est industrialisée, de Nitpick [7] à la génération de contre-exemples à l'échelle des LLM [24] — la branche réfutable de notre trichotomie ; nous avons mesuré que cette dernière ne mentionne jamais un troisième statut, et l'enquête de référence 2026 du domaine [46] organise le champ selon des axes orthogonaux au statut logique.

Guidage, plongements, environnements, mémoire. Les traits structurels de formules pour les grandes théories ont une décennie [16], avec des plongements appris invariants par symbole [29, 14] guidant la saturation et la sélection de prémisses [4, 27] ; notre détecteur partage l'objectif d'invariance mais est sans entraînement (WL exact [38]) et résout un problème différent — la coïncidence inter-théories d'axiomes caractéristiques, une tâche que nous avons trouvée non traitée. Le noyau-comme-environnement est mature [45, 19, 32] ; les mémoires de compétences d'agents validées par exécution [42] et l'apprentissage de bibliothèques en veille-sommeil [9] sont les ancêtres de la boucle hors des mathématiques. La structure de dépendances des bibliothèques est analysée à grande échelle [20, 33], topologiquement ; nous n'avons trouvé aucune métrique nommée de dette d'axiomes par dérivation. Le cadre de déploiement lui-même — l'ingénierie déployée chez le client et l'ingénierie de contexte / de harnais — vient d'acquérir une taxonomie et des critères de qualité [18, 40] ; cet article peut se lire comme une instance instrumentée et adossée à un vérificateur de cette pratique.

La nouveauté, énoncée honnêtement. Les revendications de nouveauté sont semi-décidables : on peut prouver la non-nouveauté en exhibant l'article, jamais la nouveauté. Notre revendication est donc méthodologique : après un balayage adversarial documenté, aucun contre-exemple n'a été trouvé à aucun des points suivants — des objets d'échec certifiés par le noyau à périmètre calculé ; une troisième branche (indépendance) opérationnelle ; un verdict d'infidélité mécanisé et fondé sur une dérivation contre une source imprimée préexistante ; une mesure nommée de dette d'axiomes par dérivation ; une détection d'axiomes jumeaux sans entraînement ; un chapitre I habité.

8 Limites et menaces sur la validité

Un seul esprit. Le système a été conçu, exploité et audité par un unique auteur-opérateur (avec des agents LLM sous sa direction). Les passes de vérification adversariale sont institutionnalisées précisément parce que le directeur n'est pas digne de confiance : un pronostic de triage a plus tard été mesuré faux sur ses 21 prédictions, et cet épisode est journalisé avec la même discipline que les succès. Reste que la réplication indépendante est le vrai test, et le corpus est publié pour la rendre possible.

Des retours observationnels. Les retours de la boucle de guidage (section 5) sont des instances tracées, non un effet contrôlé : la semaine ne peut pas être rejouée sans son corpus pour mesurer un contrefactuel. Ce qui survit à cette réserve : chaque instance est datée et journalisée aux deux bouts (l'échec et la réutilisation), plusieurs gains sont des rapports mécaniques indépendants de tout contrefactuel (95 minutes contre quelques secondes ; un blocage déclaré sur plusieurs sessions mesuré résolu en 4,7 secondes), et les échecs de la boucle sont enregistrés avec une discipline égale.

Échelle. 232 événements certifiés, 8 mesures de dette, 60 fabriques de théories dédiées, un livre. Chaque revendication de cet article est une revendication d'existence ou d'instance, jamais une revendication statistique. L'instrument de dette n'est valide qu'au premier appel d'un process frais (sous-comptage mesuré de -62% sinon) ; la suite complète tourne en 2 h 03 à douze workers (2 h 43 aux quatre de la semaine rapportée ici) et l'environnement tue les longues exécutions vers 50 minutes, ce qui borne le délai expérimental et a dicté la discipline de découpage.

Zones connues non mesurées. La qualité des assertions des tests hors des fichiers que nous avons édités (une dérive pourrait se cacher ailleurs derrière un test ne vérifiant que la clôture) ; les 19 usines paramétriques de théories que le détecteur de jumeaux ne couvre pas encore — la classe à risque elle-même ; la suffisance en aval des deux énoncés délibérément affaiblis ; la condition de bord de C27 dans le noyau, documentée comme dette de conception et laissée intacte par règle de projet ; un écart de fidélité nommé (sup contre maximum dans le $M(u)$ de C63) assumé et confiné. La nouveauté repose sur un balayage adversarial documenté et est semi-décidable par nature ; les cinq menaces les plus proches ont été vérifiées contre leurs PDF complets, et chaque liste d'auteurs restante contre sa page arXiv ou d'éditeur.

Généralisabilité. Tout ce qui précède jouit d'un oracle exact. Le transfert du cadre à des domaines à oracle bruité — où les certificats deviennent statistiques — est plausible mais non testé ; nous revendiquons la limite à bruit nul, non le cas général.




Figure 3: Le coup que seul un substrat où la théorie est une donnée permet. **Lecture** : chaque grand rectangle arrondi est une *théorie* (à gauche la référence T_0 , à droite son extension T') ; à l'intérieur, les boîtes bleues sont des axiomes, la boîte **orange** la définition δ ajoutée (et, à gauche, l'hypothèse orange à laquelle elle répond), la boîte verte le but désormais démontrable ; la **flèche verte en tirets** est le transport du résultat en retour dans le langage de T_0 . Quand une hypothèse est *indépendante* (ici le pont famille-valeur, indépendant de A_{T_0}), aucune recherche ne la ferme — le seul coup légal étend la théorie par une définition δ , démontre l'image, et transporte le résultat en retour.

9 Conclusion : vers une IA qui crée des théories

Le but que sert ce substrat est une IA qui *crée des théories* pour résoudre des problèmes. Dériver les exigences de ce but — des théories comme données de première classe et bon marché ; un vérificateur exact et infalsifiable ; une dette traçable ; des objets inventés comme termes ; un corpus de *processus*, échecs compris ; une métathéorie disponible à l'intérieur du système ; une réserve de couples (T, P) avec un gradient de difficulté ; des coups locaux composables ; une identité à travers les révisions ; le transport entre théories — donne une liste que nous gardons explicitement *ouverte* : elle a elle-même été prouvée incomplète une fois, par les mêmes chasses adversariales qui audient tout le reste ici, et la complétude d'une telle liste est exactement aussi semi-décidable que la fidélité. Le système décrit dans cet article en satisfait le cœur, et la semaine instrumentée est la preuve d'existence que la partie difficile — le cycle complet *détecter par dérivation, localiser par périmètre mesuré, réparer structurellement, prouver la guérison, nommer le coût* — tourne de bout en bout sur des mathématiques vivantes, deux fois.

Lu abstraitement, le système est une enquête expérimentale dans la limite à bruit nul : la falsification est une dérivation, la révision de théorie est une opération exécutable au résultat certifié, la sévérité d'un test est un compte de mutants, et l'économie de la mesure est un budget aux dépassements journalisés — Popper, Lakatos, Mayo et AGM comme code qui tourne plutôt que comme philosophie des sciences. C'est cette limite qui rend le corpus précieux comme données d'entraînement : chaque étiquette est exacte.

La feuille de route découle des mesures. Une instrumentation de jeu transforme

le corpus existant de 4 221 tests en 10^5 – 10^6 tuples certifiés (état, action, verdict) sans formaliser une seule page nouvelle — l’usine à données est la même infrastructure que le cache de termes qui supprime le coût dominant de reconstruction. Une API d’environnement (*reset*(T, P) / *step*) expose la boucle à n’importe quelle politique : les modèles de pointe sont loués et remplaçables ; ce sont la mémoire de guidage $M(s)$ et ses étiquettes certifiées qui s’accumulent et qu’aucun corpus de preuves existant ne fournit. La seconde version du détecteur de jumeaux lit le terme caractérisé dans la forme de l’axiome et couvre les usines paramétriques. Et la frontière stratégique est le chapitre IV de Bourbaki — structures et transport — parce que c’est là qu’une théorie créée pour un problème apprend à rapporter dans un autre.

Un assistant de preuve certifie ce que nous savons. Un corpus d’échecs certifiés enregistre comment nous en sommes venus à le savoir — les murs, les réparations, les prix payés — et pour une machine qui doit apprendre à *créer* des théories plutôt qu’à chercher à l’intérieur d’une seule, c’est la denrée la plus rare.

Références

- [1] Mark Adams. Proof auditing formalised mathematics. *Journal of Formalized Reasoning*, 9(1), 2016.
- [2] J. Stuart Aitken and Thomas F. Melham. An analysis of errors in interactive proof attempts. *Interacting with Computers*, 12(6):565–586, 2000.
- [3] Carlos E. Alchourrón, Peter Gärdenfors, and David Makinson. On the logic of theory change: Partial meet contraction and revision functions. *Journal of Symbolic Logic*, 50(2):510–530, 1985.
- [4] Alexander A. Alemi, François Chollet, Niklas Een, Geoffrey Irving, Christian Szegedy, and Josef Urban. DeepMath — deep sequence models for premise selection. In *Proc. NeurIPS*, 2016.
- [5] Pawan Sasanka Ammanamanchi, Siddharth Bhat, and Stella Biderman. Faults in our formal benchmarking: Dataset defects and evaluation failures in Lean theorem proving. arXiv:2606.29493, 2026.
- [6] Zhangir Azerbayev, Bartosz Piotrowski, Hailey Schoelkopf, Edward W. Ayers, Dragomir Radev, and Jeremy Avigad. ProofNet: Autoformalizing and formally proving undergraduate-level mathematics. arXiv:2302.12433, 2023.
- [7] Jasmin C. Blanchette, Lukas Bulwahn, and Tobias Nipkow. Automatic proof and disproof in Isabelle/HOL. In *Proc. FroCoS*, 2011.
- [8] Jui-Hui Chung, Ziyang Cai, Zihao Li, Qishuo Yin, et al. Goedel-Architect: Streamlining formal theorem proving with blueprint generation and refinement. arXiv:2606.06468, 2026.

- [9] Kevin Ellis, Catherine Wong, Maxwell Nye, et al. DreamCoder: Bootstrapping inductive program synthesis with wake-sleep library learning. In *Proc. PLDI*, 2021.
- [10] Emily First, Markus Rabe, Talia Ringer, and Yuriy Brun. Baldur: Whole-proof generation and repair with large language models. In *Proc. ESEC/FSE*, 2023.
- [11] José Grimm. Implementation of Bourbaki’s Elements of Mathematics in Coq: Part one, theory of sets. *Journal of Formalized Reasoning*, 3(1), 2010.
- [12] Simon Guilloud, Sankalp Gambhir, and Viktor Kunčák. LISA — a modern proof system. In *Proc. ITP*, 2023.
- [13] Li Huang, Bertrand Meyer, et al. A failed proof can yield a useful test. *Software Testing, Verification and Reliability*, 2023. arXiv:2208.09873.
- [14] Jan Jakubův, Karel Chvalovský, Miroslav Olšák, Bartosz Piotrowski, Martin Suda, and Josef Urban. ENIGMA anonymous: Symbol-independent inference guiding machine. In *Proc. IJCAR*, 2020.
- [15] Moa Johansson, Dan Rosén, Nicholas Smallbone, and Koen Claessen. Hipster: Integrating theory exploration in a proof assistant. In *Proc. CICM*, 2014.
- [16] Cezary Kaliszyk, Josef Urban, and Jiří Vyskočil. Efficient semantic features for automated reasoning over large theories. In *Proc. IJCAI*, 2015.
- [17] Ruslan Khrulev. BlueprintRepair: Typed local edits for failed Lean proof blueprints. arXiv:2607.28110, 2026.
- [18] Jiun Kim and Hyuntae Hwang. Forward deployed engineering: A taxonomy and definition. SSRN 6374660, 2026.
- [19] Guillaume Lample, Marie-Anne Lachaux, Thibaut Lavril, Xavier Martinet, Amaury Hayat, Gabriel Ebner, Aurélien Rodriguez, and Timothée Lacroix. HyperTree proof search for neural theorem proving. In *Proc. NeurIPS*, 2022.
- [20] Xinze Li, Nanyun Peng, Simone Severini, and Patrick Shafto. The network structure of Mathlib. arXiv:2604.24797, 2026.
- [21] Xue Li and Alan Bundy. An overview of the ABC repair system for Datalog-like theories. In *IJCAI-HLC Workshop (CEUR Vol. 3227)*, 2022.
- [22] Xue Li, Alan Bundy, and Eugene Philalithis. Signature entrenchment and conceptual changes in automated theory repair. arXiv:2201.08340, 2022.
- [23] Yuqing Li, Zeguan Wu, Yu Gan, and Junyu Liu. Self-modifying Lean proof agents with verifier-grounded benchmark coevolution. arXiv:2607.17352, 2026.
- [24] Zenan Li, Zhaoyu Li, Kaiyu Yang, Xiaoxing Ma, and Zhendong Su. Learning to disprove: Formal counterexample generation with large language models. arXiv:2603.19514, 2026.

- [25] Xiaokun Luan, David Sanán, Zhe Hou, Qiyuan Xu, Chengwei Liu, Yufan Cai, Yang Liu, and Meng Sun. Why the proof fails in different versions of theorem provers: An empirical study of compatibility issues in Isabelle. *Proc. ACM Softw. Eng. (FSE)*, 2:1499–1521, 2025. DOI 10.1145/3715787.
- [26] Adrian R. D. Mathias. A term of length 4,523,659,424,929. *Synthese*, 133:75–86, 2002.
- [27] Maciej Mikula et al. Magnushammer: A transformer-based approach to premise selection. In *Proc. ICLR*, 2024.
- [28] Noor Islam S. Mohammad and Tamim Sheikh. The faithfulness gap: Certifying semantic equivalence between natural-language and formal mathematical statements. arXiv:2606.16541, 2026.
- [29] Miroslav Olšák, Cezary Kaliszyk, and Josef Urban. Property invariant embedding for automated reasoning. In *Proc. ECAI*, 2020. arXiv:1911.12073.
- [30] Alison Pease. *A Computational Model of Lakatos-style Reasoning*. PhD thesis, University of Edinburgh, 2007.
- [31] Guillaume Petiot, Nikolai Kosmatov, Bernard Botella, Alain Giorgetti, and Jacques Julliand. Your proof fails? Testing helps to find the reason. In *Proc. TAP*, 2016.
- [32] Stanislas Polu and Ilya Sutskever. Generative language modeling for automated theorem proving. arXiv:2009.03393, 2020.
- [33] Ahmad Rammal, Niket Patel, Fabian Gloeckle, Amaury Hayat, Julia Kempe, Rémi Munos, Charles Arnal, and Vivien Cabannes. Formalizing mathematics at scale. arXiv:2605.29955, 2026.
- [34] Tom Reichel, R. Henderson, Andrew Touchet, Andrew Gardner, and Talia Ringer. Proof repair infrastructure for supervised models: Building a large proof repair dataset. In *Proc. ITP*, 2023.
- [35] Talia Ringer, Alex Sanchez-Stern, Dan Grossman, and Sorin Lerner. REPLica: REPL instrumentation for Coq analysis. In *Proc. CPP*, 2020.
- [36] Talia Ringer, Nathaniel Yazdani, John Leo, and Dan Grossman. Adapting proof automation to adapt proofs. In *Proc. CPP*, 2018.
- [37] Stephan Schulz, Geoff Sutcliffe, Josef Urban, and Adam Pease. Detecting inconsistencies in large first-order knowledge bases. In *Proc. CADE*, 2017.
- [38] Nino Shervashidze, Pascal Schweitzer, Erik Jan van Leeuwen, Kurt Mehlhorn, and Karsten M. Borgwardt. Weisfeiler-lehman graph kernels. *Journal of Machine Learning Research*, 12:2539–2561, 2011.

- [39] Nicolas Troquard, Roberto Confalonieri, Pietro Galliani, Rafael Peñaloza, Daniele Porello, and Oliver Kutz. Repairing ontologies via axiom weakening. In *Proc. AAAI*, 2018.
- [40] Vera V. Vishnyakova. Context engineering: From prompts to corporate multi-agent architecture. arXiv:2603.09619, 2026.
- [41] Evan Wang, Simon Chess, Daniel Lee, Siyuan Ge, Ajit Mallavarapu, Jarod Alper, and Vasily Ilin. Learning to repair Lean proofs from compiler feedback. arXiv:2602.02990, 2026.
- [42] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An open-ended embodied agent with large language models. arXiv:2305.16291, 2023.
- [43] Haocheng Wang, Baiyu Huang, Yingjia Wan, Xiao Zhu, Xiaoyang Liu, Yinya Huang, and Zhijiang Guo. FormalRx: Rectify and examine semantic failures in autoformalization. arXiv:2607.04655, 2026.
- [44] Zichen Wang, Wanli Ma, Zhenyu Ming, Gong Zhang, Kun Yuan, and Zaiwen Wen. M2F: Automated formalization of mathematical literature at scale. arXiv:2602.17016, 2026.
- [45] Kaiyu Yang and Jia Deng. Learning to prove theorems via interacting with proof assistants. In *Proc. ICML*, 2019.
- [46] Jian Zhang and Si-Cheng Tan. Automated conjecturing and theorem finding: A survey. *Journal of Computer Science and Technology*, 41(1):46–66, 2026. DOI 10.1007/s11390-026-6040-0.
- [47] Philip Zucker. Knuckledragger: A low barrier proof assistant. <https://github.com/philzook58/knuckledragger>, 2024. Python proof assistant over Z3.